Prediksi Customer Churn Menggunakan Machine Learning pada E-commerce ShopNest Tahun 2024

CAPSTON MODUL 3
MACHINE LEARNING

KHAERUN NISA'TRI SAFAATI

JKTPM36003

Table of Content

01 **Executive Summary**
Latar belakang, problem statement, goal & analytical approach

02 **Data Understanding**
Deskripsi dataset & data dictionary

03 **Exploratory Data Analysis (EDA)**
Distribusi target, insight fitur signifikan

04 **Data Cleaning & Feature Engineering**
Pipeline preprocessing — flowchart

05 **Modeling & Evaluasi**
Benchmarking & hasil test set

06 **Best Model & Explainability**
Cara kerja LightGBM & interpretasi SHAP

07 **Model Limitation**
Batasan model & alternatif peningkatan

08 **Business Impact**
Cost-Benefit Analysis

09 **Conclusion & Recommendation**
Ringkasan temuan & rekomendasi bisnis

Executive Summary

- **ShopNest,** e-commerce yang memiliki reputasi dan pengguna yang tinggi. Sampai saat ini terdapat 3,9 juta pelanggan aktif di 50+ kota di Indonesia.
- Pada 1 tahun terakhir terjadi peningkatan churn rate sebesar 17%.

.

Problem Statement

Bagaimana membangun model machine learning yang mampu mengidentifikasi pelanggan ShopNest yang berisiko churn berdasarkan data historis yang ada , dengan tujuan mengurangi churn rate melalui strategi retensi yang lebih tepat sasaran?

Analytical Approach

- Supervised Learning — Classification
- Metrik yang digunakan :
  - Recall
  - F1-Score
  - PR-AUC
  - Precision

  FN cost > FP cost → Prioritaskan Recall tinggi

Stakeholder

- Investor : C-Level & External Investor
- User :
  - Tim CRM/Marketing
  - Tim Data/Analyst
  - Product Manager

Data Understanding

3.941 baris × 11 kolom | 1 target + 10 fitur

3.941	11	8	2	~17%
Total Pelanggan	Total Kolom	Fitur Numerik	Fitur Kategorikal	Churn Rate

Kolom	Tipe	Deskripsi
Tenure	*Float*	Lama pelanggan menggunakan layanan (bulan)
WarehouseToHome	*Float*	Jarak dari gudang ke rumah pelanggan (km)
NumberOfDeviceRegistered	*Integer*	Jumlah perangkat yang terdaftar pada akun
PreferedOrderCat	*String*	Kategori produk yang paling sering dipesan
SatisfactionScore	*Integer*	Skor kepuasan pelanggan (skala 1–5)
MaritalStatus	*String*	Status pernikahan pelanggan
NumberOfAddress	*Integer*	Jumlah alamat pengiriman yang tersimpan
Complain	*Integer*	Pernah komplain: 0=Tidak, 1=Ya
DaySinceLastOrder	*Float*	Hari sejak transaksi terakhir
CashbackAmount	*Float*	Total cashback yang diterima pelanggan

EDA

Distribusi Target (Churn)

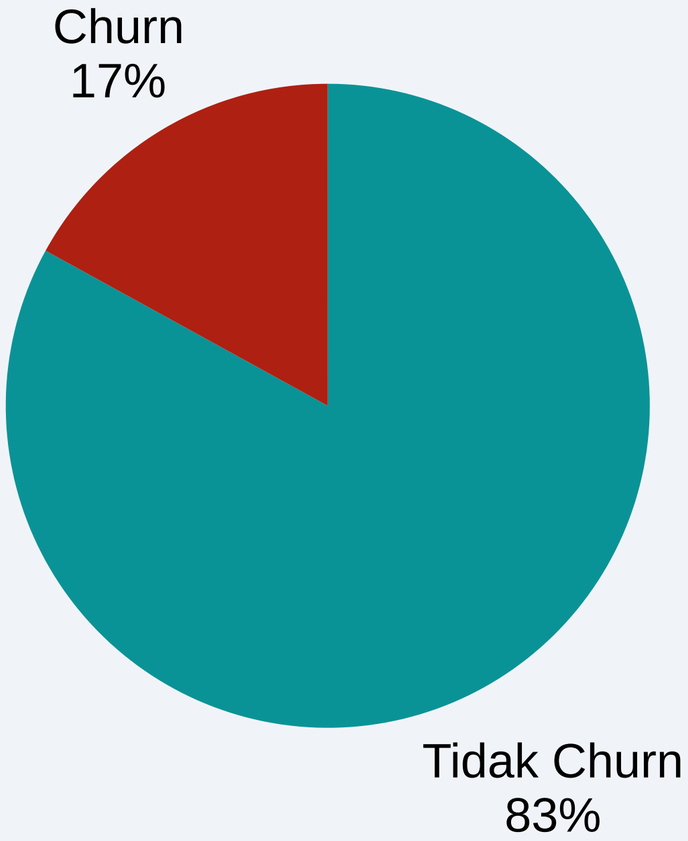

⚠️ Data Imbalanced:
hanya 17% churn → diperlukan Teknik resampling agar model tidak bias ke kelas mayoritas.

Fitur Paling Signifikan terhadap Churn

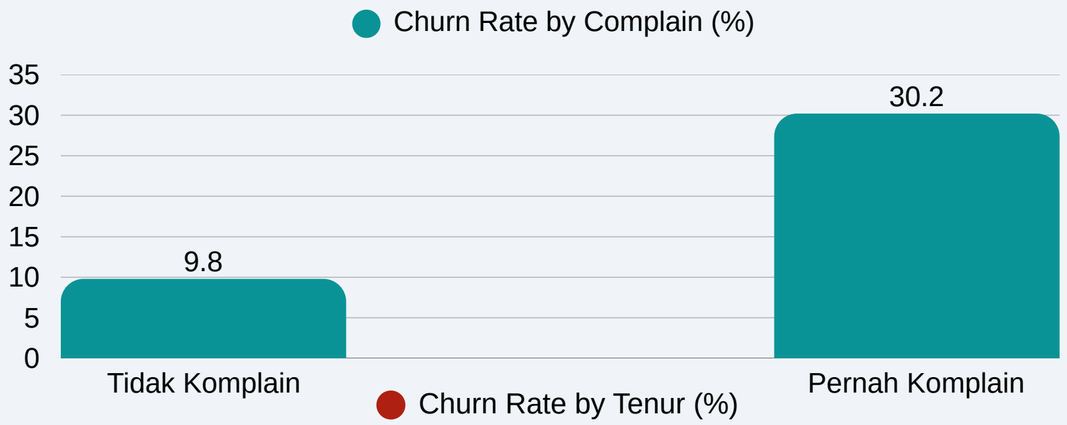

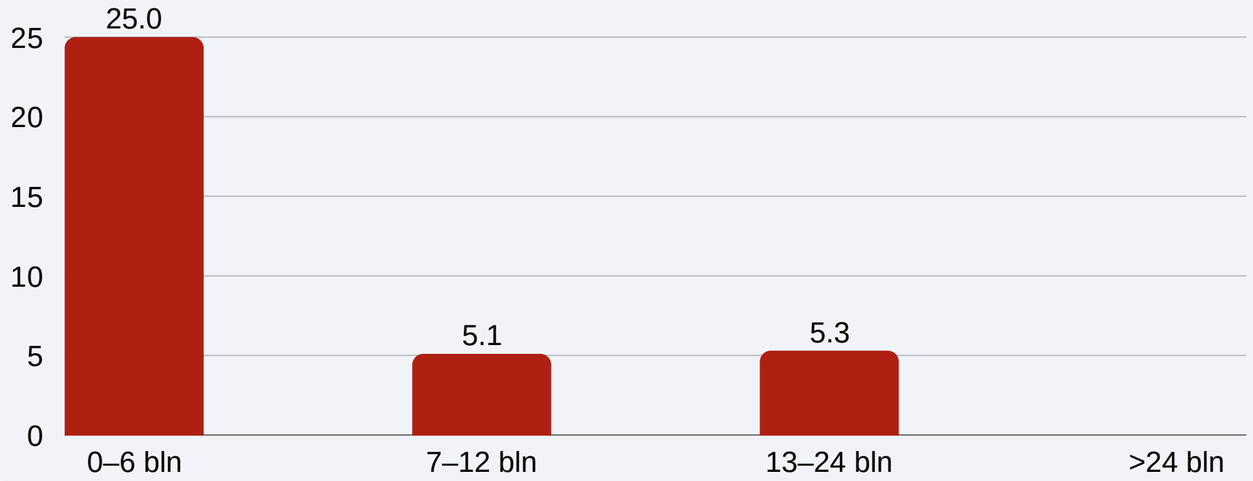

💡 Pelanggan baru (tenure rendah) & pernah komplain memiliki churn rate tertinggi. CashbackAmount rendah juga berkorelasi dengan churn.

Data Cleaning & Feature Engineering

RAW DATA
3.941 baris
11 kolom

HAPUS DUPLIKAT
Ditemukan & dihapus duplikat

HAPUS OUTLIER
WarehouseToHome > upper bound

IMPUTASI MISSING
Median (numerik)
Mode (kategorik)

ONE-HOT ENCODING
PreferedOrderCat
MaritalStatus

SCALING
StandardScaler
(LogReg & KNN)

CLEAN DATA
Siap untuk Modeling

Notes: Outlier pada kolom numerik lainnya (CashbackAmount, NumberOfDeviceRegistered, DaySinceLastOrder) **DIPERTAHANKAN** karena masih logis secara bisnis. Hanya WarehouseToHome yang dihapus (1 outlier ekstrem).

Feature Selection: Digunakan SelectPercentile dengan f_classif untuk mengevaluasi 50–100% fitur. Hasil: menggunakan **100% fitur (semua kolom)** karena peningkatan PR-AUC antar percentile minimal. Pipeline terpisah dibuat untuk model dengan scaling (LogReg, KNN) dan tanpa scaling (tree-based models).

Modeling: Summary Evaluasi pada Data Test

Benchmark 4 skenario → Best Model: ROS | LightGBM Hypertuning

Model / Benchmark	Recall	F1	PR-AUC	Precision	Keterangan
None | LightGBM (Baseline)	0.71	0.69	0.77	0.68	Baseline tanpa resampling
None | XGBoost	0.69	0.67	0.75	0.65	Baseline XGBoost
ROS | XGBoost	0.75	0.72	0.78	0.69	Oversampling + XGB
ROS | LightGBM	0.79	0.73	0.79	0.68	Oversampling + LGBM
Penalized | LightGBM	0.76	0.71	0.78	0.67	Class weight balanced
🔥 **ROS | LightGBM Hypertuning**	**0.88**	0.75	0.79	0.65	Best Model—Recall tertinggi

🔧 **Penyesuaian Threshold:** Setelah model terbaik dipilih, dilakukan optimasi threshold. Recall pada kelas churn meningkat dari **0.73 → 0.88** dengan mengorbankan sedikit precision. Threshold optimal disesuaikan untuk meminimalkan False Negative (pelanggan churn yang tidak terdeteksi).

Cara Kerja Best Model: LightGBM

Leaf-wise tree growth + gradient boosting

1

Gradient Boosting

LightGBM membangun pohon keputusan secara sekuensial. Setiap pohon baru belajar dari residual error pohon sebelumnya, sehingga model terus membaik iterasi demi iterasi.

2

Leaf-wise Tree Growth

Berbeda dari level-wise (XGBoost), LightGBM memilih leaf dengan loss reduction terbesar. Ini membuat model lebih akurat dengan pohon yang lebih dalam namun efisien.

3

Histogram-based Binning

Fitur kontinu di-bin ke dalam histogram untuk mempercepat komputasi tanpa mengorbankan akurasi secara signifikan.

4

ROS (Random OverSampling)

Data churn di-oversample agar proporsi kelas seimbang sebelum training. Ini mencegah model bias ke kelas mayoritas (tidak churn).

Hyperparameter Terpilih

learning_rate	**0.098**	Kecepatan update — tidak terlalu agresif
n_estimators	**117**	Jumlah pohon yang dibangun
num_leaves	**30**	Kompleksitas tiap pohon
max_bin	**252**	Resolusi histogram fitur
min_data_in_leaf	**35**	Minimum data per leaf (anti-overfit)
Resampling	**ROS**	Random OverSampler untuk imbalanced data

✅ Dipilih karena kecepatan training, robustness terhadap imbalanced data, dan performa Recall tinggi (0.88) dengan PR-AUC 0.79

Model Explainability: Interpretasi via SHAP

Mengapa model memprediksi seseorang sebagai 'Churn'?

Top 5 Fitur Penentu Churn (SHAP Global Importance)

CashbackAmount ↓ *rendah → churn*

Cashback rendah = pelanggan kurang diapresiasi

Tenure ↓ *baru → churn*

Pelanggan baru belum loyal

Complain ↑ *pernah → churn*

Komplain tidak tertangani → berpindah

DaySinceLastOrder ↑ *lama → churn*

Inaktif lama = sinyal meninggalkan platform

NumberOfAddress ↑ *banyak → churn*

Banyak alamat = pengguna 'coba-coba'

Membaca SHAP Values

Nilai SHAP Positif (+)

Fitur ini meningkatkan probabilitas churn.
Contoh: nilai Complain = 1 → mendorong prediksi ke arah churn.

Nilai SHAP Negatif (–)

Fitur ini menurunkan probabilitas churn.
Contoh: Tenure tinggi → pelanggan cenderung loyal dan tidak churn.

Magnitude SHAP

Semakin besar absolute SHAP value, semakin besar pengaruh fitur tersebut terhadap prediksi individu maupun global.

💡 **Action:** SHAP membantu tim CRM mengidentifikasi 'kenapa' seseorang berisiko churn, bukan hanya 'siapa'. Ini memungkinkan intervensi yang lebih personal dan tepat sasaran.

Limitasi Model

Akurasi optimal pada kondisi tertentu — area improvement tersedia

📏 Rentang Data yang Akurat

- Optimal untuk Tenure 0–48 bulan
- CashbackAmount dalam rentang IDR 0–400K
- DaySinceLastOrder ≤ 46 hari (data training)
- Churn rate sekitar 15–20% pada populasi

➕ Fitur yang Bisa Ditambahkan

- RFM Metrics (Recency, Frequency, Monetary)
- CustomerSupportInteractions (frekuensi CS)
- AppEngagementScore (aktifitas app)
- PromotionResponseRate (respon promo)
- ReturnRate & PaymentMethod
- Geolocation / Region

🔄 Alternatif Metode

- Ensemble stacking (LightGBM + XGBoost)

⏰ Maintenance & Retraining

- Retraining: setiap Q3
- Trigger: PR-AUC turun > 5% dari baseline
- Monitor concept drift pada Tenure & Cashback
- Minimum 1.000 data baru sebelum retrain

Business Impact: Cost-Benefit Analysis

Model menghasilkan ROI positif dan penghematan revenue signifikan

Asumsi Bisnis

Rp 500.000	Rp 75.000	60%
Revenue/pelanggan/tahun	Biaya intervensi/pelanggan	Success rate retensi

Lebih mahal CAC vs retensi

Perbandingan Skenario

❌ Tanpa Model (Reaktif)

Churn tidak terdeteksi: seluruh churn tidak ditangani

Revenue hilang: **Rp 100–500 Juta/tahun**
Tidak ada aksi preventif
Tim CRM bereaksi setelah pelanggan pergi

✅ Dengan Model (Proaktif)

Recall 88%: 88% pelanggan churn terdeteksi

Revenue diselamatkan: **±60% dari yang terdeteksi**
ROI intervensi: **24.9% per siklus kampanye**
Potensi hemat: **Rp 2–5 Juta/bulan (asumsi ~50 pelanggan/bln)**

📈 **Net Benefit:** Dengan model, setiap Rp 1 diinvestasikan untuk retensi menghasilkan nilai balik dalam revenue yang diselamatkan. Model dapat mengurangi kerugian revenue churn hingga **±70%** dibanding pendekatan reaktif (tanpa model).

Kesimpulan dan Rekomendasi

📌 Kesimpulan

1. LightGBM + ROS Hypertuning dipilih sebagai best model dengan Recall 0.88 dan PR-AUC 0.79
2. Data churn bersifat imbalanced (17%) — resampling (ROS) terbukti meningkatkan performa signifikan
3. 5 faktor utama churn: Cashback rendah, Tenure singkat, Pernah komplain, Inaktif lama, Banyak alamat
4. Penyesuaian threshold dari default ke optimal meningkatkan Recall dari 0.73 → 0.88
5. Model memberikan ROI positif: net benefit > biaya intervensi dalam 1 siklus kampanye

🚀 Rekomendasi

Data — Tambah fitur RFM, AppEngagement, ReturnRate, Geolocation untuk mendorong Recall > 90%

Model — Coba XGBoost tuned sebagai alternatif; tambah feature interaksi (Tenure×Complain, Cashback÷Day)

Marketing — Kirim voucher/cashback targeted ke pelanggan high-risk; prioritas: Tenure < 6 bulan & pernah komplain

Produk — Perbaiki alur komplain & onboarding pelanggan baru; program loyalitas cashback milestone

Operasional — Retrain model setiap Q3; monitor PR-AUC; batch prediction 1× sebulan untuk seluruh database

"Dengan model ini, ShopNest beralih dari reactive CRM ke proaktif — mengidentifikasi siapa yang akan pergi, sebelum mereka benar-benar pergi."

THANK YOU